

## PP index 정리

2022.09.02. 예지혜

### [1주차] 차원축소 리뷰 논문 2021-Review of Dimension Reduction Methods

#### ※ Projection Pursuit (PP)

- 데이터 탐색에 주로 쓰이는 비지도, non-parametric, 선형 차원축소 방법론
- EDA에 많이 쓰임 :
  - 저차원의 선형 투영을 찾기
  - 흥미로운 패턴 탐색 (interestingness가 PP index)
- 인덱스에 따라 다양한 패턴 감지 :
  - 분류, 군집화, 분포 추정, 회귀
- 장점 :
  - 다른 패턴 적합에도 유연하게 적용할 수 있으며, 샘플에 없는 점도 매핑할 수 있어 투영 공간에서 새로운 예시를 보여줄 수 있다.
  - 지도 학습에도 적용이 되었다.
  - 비정규성에 초점을 둔 많은 PP 인덱스가 제안되었다. ex) Legendre index<sup>1)</sup>, Hermite index, natural Hermite index, entropy index, moment index<sup>2)</sup>
- 단점 :
  - computational difficulty --> gradient 방법, Newton-Raphson method, GA, SA 등의 최적화 방법이 사용된다.

---

1) Friedman, J.H. and Tukey, J.W. (1974) A Projection Pursuit Algorithm for Exploratory Data Analysis. IEEE Transactions on Computers, C-23, 881-890.  
<https://doi.org/10.1109/T-C.1974.224051>

2) Jones, M.C. and Sibson, R. (1987) What Is Projection Pursuit? Journal of the Royal Statistical Society: Series A (General), 150, 1-37. <https://doi.org/10.2307/2981662>

### [3주차]

#### 논문 1. 1974-A Projection Pursuit Algorithm for Exploratory Data Analysis

##### ※ 선형 차원축소의 장점

- 비선형 방법보다 해석이 쉽고, 계산 비용이 적다.
- 기존 데이터에 없던 새로운 데이터에 대해서도 매핑이 가능하다.

##### ※ 선형 차원축소의 단점

- global 트렌드에만 집중하여, 그 안에 local한 클러스터들의 방향은 무시하고, global trend 방향으로만 축소하는 경향이 있다.

##### ※ PP의 장점

- global과 local 특성을 결합하여 유용한 선형 매핑을 찾아낸다.<sup>3) 4)</sup>
- trimmed global measure를 사용해 이상치에 민감하지 않다는 장점이 있다. (robustness)

##### [Projection Pursuit]

- PP는 최적의 투영을 찾기 위해 분산 뿐 아니라 데이터 간 거리(interpoint distance)를 사용하는 선형 매핑 알고리즘이다.
- 다차원의 공간에서 각 방향에 대해 "usefulness"를 나타내는 연속형의 인덱스를 찾는다. 이 인덱스는 sufficiently continuous라 최대화에 hill-climbing 알고리즘을 사용할 수 있어 계산 비용이 적게 든다.
- **Isolation과 결합하면, PP는 클러스터를 찾는 데에 유용한 방법이다.**<sup>5)</sup> PP는 각 클러스터에 대해 개별적으로 적용될 수 있어 몇 번이고 데이터를 분리할 수 있고, 계산 비용 또한 경제적이다.

##### [The Projection Index]

PP 인덱스는 인간 연구자와 컴퓨터 간 상호작용으로 결정되었는데, 연구자가 데이터를 회전시키면서 어떤 식으로 데이터의 특징을 파악하려 하는지를 인덱스에 반영하였다. 보통 클러스터 간 거리는 더 멀고, 클러스터 내부의 거리는 좁게 만드는 방향을 찾으려 했으며 인덱스 식은 다음과 같다. ( $\hat{k}$ : projection axis)

$$I(\hat{k}) = s(\hat{k})d(\hat{k})$$

$$s(\hat{k}) = \left[ \sum_{i=pN}^{(1-p)N} (X_{i \cdot \hat{k}} - \bar{X}_k)^2 / (1 - 2p)N \right]^{1/2} \quad \text{where} \quad \bar{X}_k = \sum_{i=pN}^{(1-p)N} X_{i \cdot \hat{k}} / (1 - 2p)N.$$

- 
- 3) J. B. Kruskal, "Toward a practical method which helps uncover the structure of a set of multivariate observations by finding the linear transformation which optimizes a new 'index of condensation,'" in Statistical Computation, R. C. Milton and J. A. Nelder, Ed. New York: Academic, 1969.
  - 4) -, "Linear transformation of multivariate data to reveal clustering," in Multidimensional Scaling: Theory and Application in the Behavioral Sciences, vol. 1, Theory. New York and London: Seminar Press, 1972.
  - 5) R. L. Maltson and J. E. Dammann, "A technique for determining and coding subclasses in pattern recognition problems," IBM J., vol. 9, pp. 294-302, July 1965.

: trimmed standard deviation. k 방향으로 투영했을 때 데이터의 퍼진 정도.

(N이 데이터 개수, p가 양쪽으로 자를 비율. i는 pN부터 N-pN까지만 거침.  $X_{ik}$ 는 각 데이터가 k방향으로 투영되었을 때의 값. 따라서  $X_k$ 는 trimmed mean을 의미한다. 이러한 trimmed sd를 사용함으로써 outlier에 민감하지 않은 robustness를 가진다.)

$$d(\hat{k}) = \sum_{i=1}^N \sum_{j=1}^N f(r_{ij}) 1(R - r_{ij}) \quad \text{where} \quad r_{ij} = |X_i \cdot \hat{k} - X_j \cdot \hat{k}|$$

: local density. k 방향으로 투영했을 때의 로컬 밀집도.

(r은 각 데이터가 투영됐을 때의 거리. 1 함수를 통해 거리 r이 cutoff R보다 작은 경우만 더 하므로, 로컬에 대해서만 계산된다. 일종의 window 역할이다. f는 거리에 monotonically decreasing이므로 반비례한다. 즉, d는 로컬 내에서 얼마나 뭉쳐있는지를 의미한다. - 거리가 가까울수록 큰 값을 가지므로)

※ 2차원으로의 투영

두 개의 방향  $\hat{k}$ 와  $\hat{l}$ 을 탐색하고, 서로 직교한다.

$$s(\hat{k}, \hat{l}) = s(\hat{k})s(\hat{l})$$

$$r_{ij} = [(X_i \cdot \hat{k} - X_j \cdot \hat{k})^2 + (X_i \cdot \hat{l} - X_j \cdot \hat{l})^2]^{1/2} \quad (\text{거리는 k 방향으로의 거리와 l 방향으로의 거리 합})$$

$$\bar{r} = \int_0^R r f(r) dr / \int_0^R f(r) dr \quad (\text{one dimension})$$

$$\bar{r} = \int_0^R r f(r) r dr / \int_0^R f(r) r dr \quad (\text{two dimensions})$$

둘의 차이를 잘 모르겠음

반복 실험을 통해, 로컬 밀도 탐색에 영향을 주는 건 함수  $f(r)$ 이 아니라 characteristic width (앞에서의 R로 추정됨)였다. 이 값은 로컬의 범위를 의미하므로, 알고리즘이 분포 변화에 얼마나 민감하게 반응할지를 결정하기 때문이다.

결국 인덱스 l는 로컬 집중도(d가 큰 것)와 글로벌 분산(s가 큰 것)을 동시에 측정하며, 실험을 진행하며 대부분의 연구자가 궁금해할 척도임을 확인할 수 있었다. 따라서 이 인덱스를 최대화하는 프로젝션을 찾는 것이 자연스러운 목표이다.

[One-dimensional PP]

n차원에서 1차원으로의 프로젝션은 그것의 방향을 결정하는 n-1개의 파라미터로 이루어진 함수이다. 각 방향의 코사인을 나타내며, n개의 코사인들의 제곱합이 1이 되도록 하는 제약조건을 사용한다. 이를 구하는 방법 중 하나로 Solid Angle Transform(SAT)<sup>6)</sup>이 있다.  $I(\hat{k})$ 를 최대화하는 대신 동일한 함수  $I[SAT(\hat{k})] \in E^{n-1}(-\infty, \infty)$ 를 찾아 최대화하는 방법

6) J. H. Friedman and S. Steppel, "Non-linear constraint elimination in high dimensionality through reversible transformations," Stanford Linear Accelerator Cen., Stanford, Calif., Rep. SLAC PUB-1292, Aug. 1973.

으로, 제약조건이 사라져 더 안정적인 최적화를 할 수 있다. 똑같이  $n-1$ 개의 파라미터를 찾는다.

목적함수 최적화를 위해 사용되는 수렴 기준이 목적함수 평가에 영향을 많이 미치고, 이는 계산 비용에도 많은 영향을 미쳐 몇 개의 평가를 사용할 지는 매번 달라진다.

추가적인 다양한 답을 얻기 위해 탐색하는 공간의 차원을 줄이기도 한다. 작은 분산을 가진 방향들을 제거하기도 하고 이미 얻어진 방향  $k$ 들을 이용해 임의적으로 방향을 선택하기도 한다. ( $m$ 개의 차원을 제거하여  $n-m$ 차원에서 시작)

#### [Two-dimensional PP]

- 앞서 정의한 식을 최적화
- $k$ 를 상수로 고정하고  $l$ 에 대해 최대화.  $k$ 는 문제와 관련하여 직접 정해줄 수도 있고, 1차원 projection 결과를 사용할 수도 있다.
- 하나를 고정하고 다른 하나를 구하는 과정을 두 방향이 모두 수렴할 때까지 반복

#### [Discussion]

PP는 데이터에 구조가 있으면 잘 찾아내고, 없으면 잘 찾지 못하는 것으로 보아 잘 작동하는 것을 확인하였다. PP는 선형 매핑이기 때문에 curved surface는 잘 찾지 못하는 단점이 있었으나 measurement variable로 비선형 transformation을 사용하면 spherical 클러스터링을 찾아내기도 하였다.

PP는 분산을 최대화하면서도 클러스터 내의 거리를 줄이기 때문에 데이터 구조에 방해만 되는 무관한 프로젝션을 찾는 경우를 피할 수 있었다. 또한, characteristic radius  $R$ 만 결정하면 되기 때문에 사전지식이 많이 필요하지 않다는 장점이 있다. 그 외에도 몇 차원으로 투영할 지 결정해야 하는데 2차원 투영이 1차원보다는 불안정하지만 더 많은 정보를 가지고 있다. 보통 1차원 투영 결과를 2차원 투영의 시작점으로 사용하는 것이 좋은 전략이었다.

## 논문 2. Projection Pursuit Indexes Based on Orthonormal Function Expansions

투영된 데이터의 분포와 정규분포 간의 weighted L2 거리를 나타내는 인덱스 Legendre index와 Hermite index의 차이를 살펴보고, 두 인덱스의 general form이면서도 정규분포와의 차이에 민감하도록 고안한 Natural Hermite index를 살펴본다.

normality(=randomness, 큰 엔트로피)를 null model로 두고, 엔트로피가 가장 작은 투영을 찾음으로써 정규분포와 가장 거리가 먼 투영을 찾는 것이 목적이다.

※ Polynomial expansion은 각 계수 자체를 하나의 인덱스로서 주목

- low-order indexes : long-sighted vision, 멀리서 큰 구조를 파악.

- higher-order indexes : short-sighted vision, 가까이서 내부의 복잡한 구조를 파악.

※ 기본 형태

$$I = \int_{\mathbb{R}} \{g(y) - \psi(y)\}^2 \psi(y) dy,$$

$Y = T(X)$ ,  $T: \mathbb{R} \rightarrow \mathbb{R}$  (Y는 X의 transformation. 특정 구조에 민감하게 반응하도록 진행)  
X의 분포함수  $F(x)$ , 밀도함수  $f(x)$ , Y의 분포함수  $G(Y)$ , 밀도함수  $g(y)$

X 관점에서 표현하면,

$$\begin{aligned} I &= \int_{\mathbb{R}} \left\{ \frac{f(x)}{T'(x)} - \frac{\phi(x)}{T'(x)} \right\}^2 \phi(x) dx \\ &= \int_{\mathbb{R}} \{f(x) - \phi(x)\}^2 \frac{\phi(x)}{T'(x)^2} dx. \end{aligned}$$

이 인덱스는 X와 표준정규분포  $\phi(x)$  간 가중치 L2 거리이며, 가중치는  $\phi(x)/T'(x)^2$ 이다.

- 인덱스 I는 f에 대한 함수.

- f는 투영 벡터  $\alpha$ 에 의존하므로, PP는 모든 가능한  $\alpha$ 에 대한 인덱스의 local maxima를 찾는 과정을 포함한다.

Transformation family of T를 다음과 같이 정의하면 세 인덱스를 이렇게 정리할 수 있다.

$$T_{\sigma}(X) = \sqrt{2\pi\sigma}(\Phi_{\sigma}(X) - 1/2)$$

Legendre Index (by Friedman)	Hermite Index (by Hall)	Natural Hermite Index
$I^L = \int_{\mathbb{R}} \{f(x) - \phi(x)\}^2 \frac{1}{2\phi(x)} dx,$	$I^H = \int_{\mathbb{R}} \{f(x) - \phi(x)\}^2 dx.$	$I^N = \int_{\mathbb{R}} \{f(x) - \phi(x)\}^2 \phi(x) dx.$
$T(X) = 2\Phi(X) - 1$ $T'(X) = 2\phi(X)$	$T(X) \propto \Phi_{\sigma=\sqrt{2}}(X)$ $T'(X) = \sqrt{\phi(x)}$	$T(X) = X$ , identity 변형
$T_{\sigma=1}$	$T_{\sigma=\sqrt{2}}$	$T_{\infty}$
가중치는 정규분포의 역수로, 꼬리에 대한 가중치	가중치 항상 1	가중치는 정규분포 식으로, center에 대한 관심

**[5주차] 2015 - a projection pursuit framework for supervised dimension reduction of high dimensional small sample datasets**

유전자 데이터와 같은  $n \ll p$  데이터는 PP를 적용하기에 계산 비용이 크고, poor local을 찾는다는 단점이 있어, 이러한 데이터에 맞게 데이터를 먼저 압축하고 PP를 적용하는 PP framework를 제안한 논문이다. 이 논문에서는 PCA, whitening, PLS 3가지의 차원축소 방법과 5가지의 PP 인덱스를 결합하여 그 성능을 비교한다.



**※ PP 인덱스**

- clustering을 위한 인덱스<sup>7)8)9)10)11)12)13)</sup>
- supervised 분석을 위한 인덱스 : 원래 그룹 정보가 존재하여 이를 활용
- regression을 위한 인덱스<sup>14)15)</sup>

이 논문에서는 supervised classification에 초점을 두어 다음과 같은 5개의 인덱스를 사용한 다. 이 인덱스값들을 maximize하는 투영 a를 찾는 것이 PP의 목적이다.

**1) Index Bhattacharya (Bat)<sup>16)17)</sup>**

그룹간 Bhattacharya 거리로, 각 i와 j는 서로 다른 그룹을 의미한다.

$\mu_i$  : 그룹 i에 속하는 데이터들의 투영 Xa의 평균 /  $\sigma_i$  : 분산

$$\mathfrak{J}_{Bat} = \min_{i,j \in C} \left\{ \frac{1}{4} \frac{(\mu_i - \mu_j)^2}{\sigma_i + \sigma_j} + \frac{1}{2} \log \left( \frac{\sigma_i + \sigma_j}{2\sqrt{\sigma_i \sigma_j}} \right) \right\},$$

- 
- 7) [42] I. Perisic, C. Posse, Projection pursuit indices based on the empirical distribution function, J. Comput. Graph. Stat. 14 (3) (2005) 700-715.
- 8) [19] D. Pena, F. Prieto, Cluster identification using projections, J. Am. Stat. Assoc. 96 (456) (2001) 1433-1445.
- 9) [38] C. Posse, Projection pursuit exploratory data analysis, Comput. Stat. Data Anal. 20 (1995) 669-687.
- 10) [39] C. Posse, Tools for two-dimensional exploratory projection pursuit, J. Comput. Graph. Stat. 4 (2) (1995) 83-100.
- 11) [43] D. Cook, A. Buja, J. Cabrera, Projection pursuit indexes based on orthonormal function expansions, J. Comput. Graph. Stat. 2 (3) (1993) 225-250.
- 12) [30] M.C. Jones, R. Sibson, What is projection pursuit? J. R. Stat. Soc. Ser. A: General 150 (1) (1987) 1-37.
- 13) [13] J.H. Friedman, J.W. Tukey, A projection pursuit algorithm for exploratory data analysis, IEEE Trans. Comput. 23 (9) (1974) 881-890.
- 14) [46] J.H. Friedman, W. Stuetzle, Projection pursuit regression, J. Am. Stat. Assoc. 76 (1981) 817-823.
- 15) [47] P. Hall, On projection pursuit regression, Ann. Stat. 17 (2) (1989) 573-588.
- 16) [28] E. Rodriguez-Martinez, J.Y. Goulermas, T. Mu, J.F. Ralph, Automatic induction of projection pursuit indices, IEEE Trans. Neural Netw. 21 (8) (2010) 1281-1295.
- 17) [5] L. Jimenez, D. Landgrebe, Hyperspectral data analysis and supervised feature reduction via projection pursuit, IEEE Trans. Geosci. Remote Sens. 37 (6) (1999) 2653-2667.

## 2) Index quality projected clusters (qpc)<sup>18)19)</sup>

compact pure한 클러스터를 찾는 인덱스

$\alpha$  : 각 데이터  $i, j$ 에 대해 같은 그룹이면  $\alpha$ 는 양수, 다른 그룹이면 음수 값을 가진다.

함수  $G(\cdot)$  :  $x=0$ 에서 가장 큰 값을 가지는 함수로, 가우시안 함수를 사용할 수 있다.

투영된 거리가 가까울수록 큰 값을 가지므로, 이 인덱스를 최대화하면 같은 그룹끼리 잘 뭉쳐지고, 다른 그룹끼리 잘 분리되는 투영을 찾을 수 있다.

$$\mathfrak{I}_{qpc} = \sum_{i,j=1}^n \alpha_{ij} G((x_i - x_j)\mathbf{a}),$$

## 3) Index Fisher linear discriminant analysis (lda)<sup>20)21)22)</sup>

LDA 방법으로, 그룹 간 거리는 크게, 그룹 내 거리는 작게 하는 투영을 찾는다.

$$\mathfrak{I}_{lda} = 1 - \frac{|\mathbf{A}^T \mathbf{W} \mathbf{A}|}{|\mathbf{A}^T (\mathbf{W} + \mathbf{B}) \mathbf{A}|},$$

## 4) Index neighborhood components analysis (nca)<sup>23)</sup>

nca 방법론의 비용함수로 사용되는 인덱스로, 올바른 그룹으로 분류되었을 확률을 의미한다.

$$\mathfrak{I}_{nca} = \sum_i^n \sum_{j \in \Omega_i} p_{ij},$$

$$p_{ii} = 0 \text{ and } p_{ij} = \exp(-\|x_i \mathbf{A} - x_j \mathbf{A}\|^2) / \sum_{k \neq i} \exp(-\|x_i \mathbf{A} - x_k \mathbf{A}\|^2)$$

## 5) Index locality preserving (Lp)<sup>24)</sup>

Locality Preserving Projections (Lpp) 방법의 비지도 학습 인덱스이다.

인접한 데이터들을 함께 모으는 투영을 찾아낸다.

---

18) [24] M. Grochowski, W. Duch, Fast projection pursuit based on quality of projected clusters, in: A. Dobnikar, U. Lotric, B. Ster (Eds.), Adaptive and Natural Computing Algorithms Lecture Notes in Computer Science, vol. 6594, Springer, Berlin, Heidelberg, 2011, pp. 89-97.

19) [44] M. Grochowski, W. Duch, Projection pursuit constructive neural networks based on quality of projected clusters, in: V. Kurkova, R. Neruda, J. Koutnik (Eds.), Artificial Neural Networks-ICANN 2008, PT II, Lecture Notes In Computer Science, vol. 5164, 2008, pp. 754-762.

20) [27] J.R. Jee, Projection pursuit, Wiley Interdiscip. Rev.: Comput. Stat. 1 (2) (2009) 208-215.

21) [21] E. Lee, D. Cook, S. Klinke, T. Lumley, Projection pursuit for exploratory supervised classification, J. Comput. Graph. Stat. 14 (4) (2005) 831-846.

22) [45] E.-K. Lee, D. Cook, A projection pursuit index for large p small n data, Stat. Comput. 20 (3) (2010) 381-392.

23) [48] J. Goldberger, S. Roweis, G. Hinton, R. Salakhutdinov, Neighbourhood components analysis, in: Advances in Neural Information Processing Systems, vol. 17, 2005, pp. 513-520.

24) [52] X. He, S. Yan, Y. Hu, P. Niyogi, H. Jiang Zhang, Face recognition using Laplacianfaces, IEEE Trans. Pattern Anal. Mach. Intell. 27 (2005) 328-340.

L : Laplacian matrix of k-neighborhood graph

$$\mathfrak{I}_{Lp} = 1 / (A^T X L A),$$

(오타로 추정됨.  $1 / (A^T X L X^T A)$  )

이 논문의 결과, PCA+LDA 조합이 가장 성능이 좋았고, qpc와 Lp 인덱스는 대체로 성능이 좋지 않았다.



## [6주차] 2018-PPtreeViz-An R package for visualizing projection pursuit classification trees

classification을 위한 PP를 진행하기 위해 만든 R 패키지. 최적화에는 속도를 위해 Rcpp와 RcppArmadillo 패키지를 사용.

### ※ 패키지에서 제공하는 인덱스

1) LDA 인덱스 - 5주차 논문과 동일

$$I_{LDA,W}(\mathbf{A}) = 1 - \frac{|\mathbf{A}^\top \mathbf{W} \mathbf{A}|}{|\mathbf{A}^\top (\mathbf{W} + \mathbf{B}) \mathbf{A}|}$$

2) PDA index

LDA를 적용하고 싶은데 변수간 상관관계가 높을 때 사용하는 인덱스.

상관관계가 높으면 LDA 인덱스의 분모가 0으로 가기 때문에 off-diagonal 행렬에 패널티  $\lambda$ 를 부여하여 식을 수정함.  $\lambda$ 가 0이면 LDA 인덱스와 동일, 1이면 모든 변수간 상관도 제거.

$$I_{PDA,W}(\mathbf{A}, \lambda) = 1 - \frac{|\mathbf{A}^\top \mathbf{W}_{PDA} \mathbf{A}|}{|\mathbf{A}^\top (\mathbf{W}_{PDA} + \mathbf{B}) \mathbf{A}|}$$

where

$$\mathbf{W}_{PDA} = \text{diag}(\mathbf{W}) + (1 - \lambda)\text{offdiag}(\mathbf{W})$$

$$\text{diag}(\mathbf{W}) = \text{diag}(w_{11}, \dots, w_{pp})$$

$$\text{offdiag}(\mathbf{W}) = \mathbf{W} - \text{diag}(\mathbf{W})$$

3)  $L_r$  index

4) 1D Gini index

5) 1D entropy index

[코드] PPtreeViz 패키지에 5주차 논문의 다섯 가지 인덱스를 적용한 실습 파일 존재.

## [8주차] Using\_Projection-Based\_Clustering\_to\_Find\_Distance

고차원 데이터에서 거리와 밀도 구조(DDS, distance and density structures)에 의해 형성되는 클러스터를 잡아내기 위해 투영과 클러스터링을 동시에 진행하는 PBC를 제안한 논문이다. PBC는 topographic map을 통해 클러스터의 경향과 개수 둘다 잘 파악하게 한다. 실험을 통해 32개의 방법론과 비교했으며, PBC는 항상 우수한 성능을 보였다.

### 1) Combining DR with Clustering k-means (9개)

- PPCI 패키지<sup>25)</sup> : PP를 클러스터링과 결합. **PPC\_MD<sup>26)</sup> (MinimumDensity)**, **PPC\_MC<sup>27)</sup> (MaximumClusterbility)**, **PPC\_NC<sup>28)</sup> (NormalisedCut)**, Kernel\_PCA\_Clust<sup>29)</sup>
- tandem clustering : 변수 일부만 중요할 때, PCA나 FA를 적용한 후 k-means로 클러스터링을 진행하는 방법. clustrd 패키지 사용. RKM, FKM, KM, KM\_I12

### 2) Conventional Clustering Algorithms (5개)

- K-means, SL, Spectral, Ward, PAM, MoG

### 3) Benchmarking of 18 Clustering Algorithms (18개)

- SOM, ADP, AP, DBscan, fuzzy, Markov, QTC, SOTA, CLARA, neural gas, HCL, hierarchical (complete, average, mcquitty, median, centroid linkage), DIANA
- : 모두 FCPS 패키지 사용.

## 2019-PPCI an R Package for Cluster Identification using Projection Pursuit

PP가 찾은 최적의 투영으로 계층적 클러스터링을 반복하는 방법을 R 패키지로 구현한 논문이다. (PP, clustering) 조합으로 (mdh, mddc), (mch, mcdc), (ncuth, ncutdc) 3개의 조합을 제안하였다.

---

25) Hofmeyr, D., & Pavlidis, N. (2019). PPCI: an R package for cluster identification using projection pursuit. The R Journal, 11, 152. (<https://CRAN.R-project.org/package=PPCI>) (Hofmeyr and Pavlidis 2019).

26) Pavlidis, N. G., Hofmeyr, D. P., & Tasoulis, S. K. (2016). Minimum density hyperplanes. The Journal of Machine Learning Research, 17, 5414-5446.

27) Hofmeyr, D., & Pavlidis, N. (2015). Maximum clusterability divisive clustering. In 2015 IEEE symposium series on computational intelligence (pp. 780-786). Piscataway, NJ: IEEE.

28) Hofmeyr, D. P. (2016). Clustering by minimum cut hyperplanes. IEEE Transactions on Pattern Analysis and Machine Intelligence, 39, 1547-1560.

29) Hofmeyr, D., & Pavlidis, N. (2019). PPCI: an R package for cluster identification using projection pursuit. The R Journal, 11, 152.

### [10주차] A Section Pursuit Index for Finding Hidden Structure in Multiple Dimensions

선형 투영이 데이터의 중심에 있는 패턴을 잡아내지 못하는 문제를 해결하기 위해, section pursuit 방법으로 슬라이스를 찾아내는 방법을 제안한다.

#### ※ Tour

##### - Ground Tour

데이터를 계속 회전시키며 저차원에 투영하여 살펴보는 방법으로, 주로 2차원 projection plane에 투영시켜 사람이 직접 그 변화를 확인한다.

##### - Slicing

Ground Tour의 projection plane으로부터 각 데이터 포인트 간의 직교 거리를 계산하여, 그 거리가 cutoff  $h$ 보다 짧으면 슬라이스 내부, 그 바깥에 존재하면 슬라이스 외부로 간주한다. 이러한 방식으로 슬라이스 내부와 외부의 분포를 비교하여 holes와 grains를 찾아낼 수 있다.

##### - Guided Tour

Grand tour에 PP를 결합한 개념으로, PP 인덱스를 최적화시키며 projection plane을 선택하고, 인덱스에 따라 원하는 패턴을 찾아낼 수 있다.

#### ※ Index 정의<sup>30)</sup>

$Y = XA$ ,  $p$ 차원의 데이터  $X$ 를  $A$  벡터를 통해  $d$ (보통 2)차원의  $Y$  plane으로 투영한다.

- 각 데이터 포인트로부터  $Y$  평면까지의 유클리디안 거리  $h$

$$h_i = ||\mathbf{x}_i - (\mathbf{x}_i \cdot \mathbf{a}_1)\mathbf{a}_1 - (\mathbf{x}_i \cdot \mathbf{a}_2)\mathbf{a}_2||$$

$k$ 개의 bin이 있다고 정의하여, 해당 bin의 슬라이스에 들어가면  $S_k$ 에 1을 더하고, 해당 bin이지만 슬라이스에 들어가지 않으면  $C_k$ 에 1을 더한다. (즉,  $S$ 와  $C$ 는 개수)

$$S_k = \sum_i I(Y_i \in b_k) I(h_i < h), \quad C_k = \sum_i I(Y_i \in b_k) I(h_i \geq h)$$

Hole Index	Grain Index
$I_A^{\text{low}} = \sum_k [(c_k - s_k)]_{>\epsilon},$	$I_A^{\text{up}} = \sum_k [(s_k - c_k)]_{>\epsilon}$
(외부-내부) 개수이므로, 이 인덱스가 크면 외부의 데이터가 많아 hole이다.	(내부-외부) 개수이므로, 이 인덱스가 크면 내부에 데이터가 많아 grain이다.

$\epsilon$ 은 노이즈를 피하고 bin 개수에 의한 인위적인 영향을 피할 수 있게 한다.

특정 bin을 강조하거나 민감도를 조정하기 위해 다음과 같이 일반화될 수 있다.

$$I_A^{\text{low}} = \sum_k w_k \left( [c_k^{1/q} - s_k^{1/q}]_{>\epsilon} \right)^q, \quad I_A^{\text{up}} = \sum_k w_k \left( [s_k^{1/q} - c_k^{1/q}]_{>\epsilon} \right)^q.$$

30) Gous, A., and Buja, A. (2004), "Visual Comparison of Datasets Using Mixture Decompositions," Journal of Computational and Graphical Statistics, 13, 1-19. [3]